

Apunte de estudio

Estadística descriptiva, inferencia y una introducción a Machine Learning

LA PREGUNTA DE LA UNIDAD

¿El segmento A es realmente distinto del segmento B?

En California: ¿las casas cerca del mar valen más que las de tierra adentro? En el NEA: ¿Gran Resistencia es más pobre que Corrientes?

Este apunte junta en un solo lugar lo que tenés que saber de las tres clases de la unidad: las fórmulas, la intuición que hay detrás y los errores que conviene evitar. Sigue el orden de las clases y usa sus mismos ejemplos, así que se lee al lado de las slides y de las notebooks: no las reemplaza.

El recorrido

parte	la pregunta	los temas	pág.
Clase 1 · Fundamentos puntos 1 y 2 · notebooks 01 y 02	¿Puedo confiar en estos datos? ¿Cómo es cada variable?	sesgo · tipos de variable · calidad · frecuencias · media, mediana y moda · posición · dispersión	2
Clase 2 · Bivariado y visualización puntos 3 y 4 · notebooks 03 y 04	¿Se ven distintos? ¿Qué los relaciona?	covarianza y correlación · causalidad · límites de r · tablas cruzadas · Simpson · atípicos · gráficos	6
Clase 3 · Inferencia y Machine Learning punto 5 · notebooks 05 y 06	¿Esto vale fuera de mis datos?	error estándar · z · intervalos de confianza · contraste de hipótesis · Machine Learning	10
Hoja de fórmulas	todas las fórmulas de la unidad, en una página		14
Respuestas del repaso	cada clase cierra con preguntas para autoevaluarte		15

Cómo se lee cada tema

Todos los temas siguen el mismo esquema, y cada uno usa sólo los bloques que le sirven:

LA FÓRMULA

en un recuadro, con qué es cada símbolo

LA INTUICIÓN

por qué funciona, con el ejemplo o la analogía de la clase

OJO

dónde se rompe: los errores que conviene evitar

EN PANDAS

la línea de código que lo calcula

PARA FIJAR

la idea, en una frase

Los datos de los ejemplos

California Housing. El censo de Estados Unidos de 1990: 20.640 barrios de California. La variable protagonista es `median_house_value`, el valor mediano de las viviendas de cada barrio, y los segmentos salen de `ocean_proximity`, la cercanía al mar.

La EPH del INDEC. La pobreza del primer semestre de 2026, con foco en las ciudades del NEA.

Préstamos ficticios. El caso de Machine Learning: una financiera que decide a quién prestarle. Todos sus números son inventados.

Fundamentos

LA PREGUNTA DE LA CLASE

¿Puedo confiar en estos datos? ¿Cómo es cada variable?

1.1 · Población, muestra y sesgo

La **población** es todo aquello sobre lo que querés concluir; la **muestra**, los datos a los que tenés acceso. Hay **sesgo** cuando el mecanismo que elige a quién medís deja afuera, siempre del mismo lado, a una parte de la población.

La intuición. En 1936, la revista *Literary Digest* juntó 2,4 millones de respuestas y erró el ganador de la elección de Estados Unidos; Gallup, con 50.000, acertó. La revista le preguntó a la gente equivocada: sus listas salían de guías telefónicas y registros de autos, que en esos años dejaban afuera a los más pobres. En la Segunda Guerra, Abraham Wald miró los agujeros de los aviones que volvían y propuso blindar *donde no había*: los impactos que faltaban eran los de los aviones que no volvieron.

OJO Pasa todo el tiempo. Si preguntás "¿están conformes los clientes?", contestan los conformes, no los que se fueron; si medís cuánto tarda un trámite, medís los que se completaron, no los abandonados. La pregunta que importa es **quién falta**.

Describir no es inferir. "Estos barrios cerca de la bahía *valieron* 259.212 en promedio" describe lo que mediste; "las casas cerca del mar *valen* más" habla de lo que no mediste, y eso es inferencia (Clase 3). Un censo no tiene error de muestreo, pero el problema cambia de forma: California Housing es de 1990 y de California. ¿Sirve para decidir algo hoy, o en Corrientes?

PARA FIJAR Más datos no arreglan una muestra torcida: la amplifican.

1.2 · Qué es una fila y qué tipo es cada variable

Antes de calcular, hay que saber qué representa una fila. En California Housing, una fila es un **barrio** (un *block group* de 600 a 3.000 personas), no una casa. Y del **tipo** de cada variable dependen las cuentas y los gráficos que tienen sentido:

tipo	qué es	ejemplo
nominal	categorías sin orden	<code>ocean_proximity</code> , el color de ojos
ordinal	categorías con orden, pero sin distancias	el nivel educativo, el grado de satisfacción
discreta	se cuenta: valores separados	<code>households</code> , la cantidad de hijos
continua	se mide: admite decimales	<code>median_income</code> , la altura


OJO El **dtype no alcanza**: pandas guarda, vos interpretás. `housing_median_age` es `float64`, pero está topeada en 52 (1.273 barrios); `median_income` está en decenas de miles de dólares y topeada en 15,0001; `latitude` y `longitude` sólo tienen sentido en par; y si `ocean_proximity` es nominal u ordinal, lo decidís vos.

1.3 · El primer vistazo y la calidad de los datos

en pandas	qué pregunta	qué buscar
<code>df.info()</code>	¿qué tipos leyó pandas?	cuántos datos faltan; números leídos como texto
<code>df.describe()</code>	¿los números son razonables?	mínimos y máximos; media contra mediana. Ignora las columnas de texto.
<code>x.value_counts()</code>	¿cómo se reparten los valores?	un valor que domina, o una categoría casi vacía

Un dato puede estar mal sin ser NaN. En `median_house_value`, 965 barrios (el 4,68%) valen exactamente 500.001 dólares: no es un precio, es un **tope**. No es el único: `housing_median_age` está topeada en 52 y `median_income`, en 15,0001. Y los defectos **vianan**: reaparecen en las columnas que calculás a partir de ellos.

OJO Con 5 barras, el pico del tope queda escondido dentro de la última; con 50, salta a la vista. La cantidad de barras (bins) cambia la historia: probá varias antes de elegir.



Un histograma delata un tope mejor que cualquier tabla.

PARA FIJAR Ningún resumen te ahorra mirar los datos.

1.4 • La tabla de frecuencias

Cuenta cuántas veces aparece cada valor, o cada tramo si la variable es continua. Tiene tres columnas: la frecuencia **absoluta** (cuántos hay), la **relativa** (qué proporción del total) y la **acumulada** (cuántos hay hasta ese valor).

$$f_i = \frac{n_i}{n} \quad F_i = n_1 + n_2 + \dots + n_i$$

n_i : la frecuencia absoluta del valor i · n : el total · f_i : la relativa · F_i : la acumulada. Las relativas suman 1.

nota	absoluta	relativa	acumulada
1	1	0,05	1
2	2	0,10	3
3	6	0,30	9
4	7	0,35	16
5	4	0,20	20

Las notas de 20 estudiantes, de 1 a 5.

EN PANDAS `x.value_counts(normalize=True).sort_index().cumsum()`

1.5 • Tendencia central: media, mediana y moda


$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

Media: la suma de los valores dividida por cuántos son. **Mediana:** el valor del medio con los datos ordenados (si n es par, el promedio de los dos del medio). **Moda:** el valor más frecuente; es la única que sirve para categóricas.

La intuición. La media es el **punto de equilibrio**: si un valor se va lejos, el equilibrio se corre con él. La mediana sólo mira el **orden**: al último dato lo podés mandar lejísimo y no cambia. Cinco barrios de 100.000, 200.000, 300.000, 400.000 y 500.000 tienen media y mediana de 300.000; si alguien tipea 50.000.000 en vez de 500.000, la media pasa a 10.200.000 y la mediana sigue en 300.000.


Simétrica

media = mediana = moda




Cola a la derecha

moda < mediana < media



Cola a la izquierda

media < mediana < moda



..... moda ————— mediana - - - - media

La forma manda. Con cola a la derecha (precios, ingresos), la media queda arriba de la mediana; con cola a la izquierda (las notas de un parcial fácil), abajo. Si es simétrica (paquetes de yerba de 1 kg), coinciden.

En housing, la media es 206.856 y la mediana 179.700: hay una cola a la derecha, y el 59,4% de los barrios está por debajo del "promedio".

OJO La robustez de la media **depende de n**: el mismo error de carga la mueve un 457% en una muestra de 50 barrios y un 1,2% con los 20.640. Un problema de calidad también puede cambiar la **forma**: el tope le cortó la cola a los precios y su asimetría quedó en 0,98, como si fuera casi simétrica (*population* , sin tope, tiene 4,94; topeada en su percentil 95, baja a 0,93). Y la moda de los precios es 500.001: en una continua, la moda sirve para delatar topes.

EN PANDAS `x.mean()` `x.median()` `x.mode()`

PARA FIJAR Media y mediana responden preguntas distintas: cuando se separan, hay una cola. Con colas o errores, el valor típico es la mediana.


1.6 • Posición: percentiles, cuartiles e IQR

El **percentil p** deja al p% de los datos por debajo. Los **cuartiles** son los percentiles 25, 50 y 75: Q1, Q2 (la mediana) y Q3.

$$IQR = Q_3 - Q_1 \quad \text{vallas: } Q_1 - 1,5 \cdot IQR \quad \text{y} \quad Q_3 + 1,5 \cdot IQR$$

El IQR es el ancho del 50% central de los datos. Lo que cae fuera de las vallas se marca como atípico.

En housing, Q1 = 119.600 y Q3 = 264.725: el 50% central de los barrios vale entre esos dos números, el IQR es 145.125 y la valla de arriba queda en 482.412.



El boxplot dibuja esos números: la caja es el 50% central y los bigotes llegan hasta el último dato que no pasa la valla. Abajo no hay atípicos: $Q_1 - 1,5 \cdot IQR$ da negativo.

OJO La regla marca 1.071 barrios como atípicos, pero 965 de ellos (el 90%) son el tope. "Atípico" no quiere decir "error", ni tampoco "real": quiere decir "lejos del centro según esta regla". Qué es cada punto lo tenés que averiguar vos.

EN PANDAS `q1, q3 = x.quantile([0.25, 0.75])`

1.7 • Dispersión: varianza y desvío estándar

El centro no alcanza: [49, 50, 51] y [0, 50, 100] tienen media 50 y no se parecen en nada. El **rango** (máximo – mínimo) usa sólo dos datos; la varianza usa todos.

$$s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1} \quad s = \sqrt{s^2}$$

s^2 : la varianza · s : el desvío estándar · $x_i - \bar{x}$: la distancia de cada dato a la media.

La intuición. La varianza es el promedio de las distancias a la media, **al cuadrado**: con su signo, las de arriba y las de abajo se cancelan, y $\sum (x_i - \bar{x})$ siempre da 0. El cuadrado deja todo positivo, pero también eleva las unidades: "dólares al cuadrado" no significa nada. Por eso se reporta el **desvío**, que vuelve a la unidad original: los barrios de housing se alejan de la media unos 115.396 dólares.

¿Por qué n – 1? Las distancias se miden contra la media de la propia muestra, que es el punto más cercano posible a esos datos: dividir por n subestimaría la dispersión. La diferencia entre las dos versiones es $n/(n - 1) - 1$: 50% con n = 3, 3,4% con n = 30 y 0,005% con los 20.640 barrios.

OJO pandas divide por n – 1 (`.var()` , `.std()`); numpy, por n (`np.var()` , `np.std()`). Si tu resultado no coincide con el de un compañero, empezá por ahí. Con muestras grandes la diferencia no importa; con muestras chicas, es decisiva.

EN PANDAS `x.var()` `x.std()`

1.8 · Coeficiente de variación

$$CV = \frac{s}{\bar{x}}$$

El desvío en proporción a la media. No tiene unidades.

La intuición. El desvío está en la unidad de la variable, así que no compara grupos de escalas distintas. Por desvío, el grupo más variable de housing es NEAR BAY (122.819 dólares) y el menos variable, INLAND (70.008). Por CV, el orden se invierte: INLAND 0,561 contra NEAR BAY 0,474. En proporción a lo que vale una casa ahí, el precio de INLAND es más difícil de anticipar.

OJO ISLAND tiene el CV más bajo (0,212) y la media más alta (380.440), pero son **5 barrios**: un CV bajo sobre 5 datos dice que esos cinco se parecen, nada más. Y el CV sólo sirve en variables positivas con un cero de verdad (precios, cantidades): con la media cerca de cero, explota.

EN PANDAS `x.std() / x.mean()`

PARA FIJAR El desvío no compara escalas distintas; el CV sí.

LO QUE TENÉS QUE SABER

1. Más datos no arreglan una muestra torcida.
2. El dato que falta es importante: preguntate quién no está.
3. Un dato puede estar mal sin ser NaN: el tope de 500.001.
4. Un problema de calidad puede cambiar la forma: el tope hizo parecer simétrica una variable que no lo es.
5. Media y mediana responden preguntas distintas.
6. La varianza está en unidades al cuadrado: por eso se reporta el desvío.
7. El desvío no compara escalas; el CV sí.
8. Podemos ver una diferencia; todavía no podemos afirmarla.

PREGUNTAS DE REPASO

- 1.1 Una encuesta online sobre la atención al cliente recibe 50.000 respuestas. ¿Alcanza ese tamaño para confiar en el resultado?
- 1.2 En una variable de ingresos, la media es 850.000 y la mediana 620.000. ¿Qué forma tiene la distribución? ¿Qué número darías como "ingreso típico"?
- 1.3 Calculá a mano la varianza y el desvío de [2, 4, 9]. ¿Cuánto cambia la varianza si dividís por n en vez de por n - 1?
- 1.4 La sucursal A vende en promedio 200 unidades por día, con un desvío de 40; la B, 2.000, con un desvío de 300. ¿Cuál tiene ventas más variables?

Bivariado y visualización

LA PREGUNTA DE LA CLASE

¿Se ven distintos? ¿Qué los relaciona?

Desde esta clase se miran **dos variables a la vez**, y aparecen tres errores imposibles de cometer mirando de a una: creer que una correlación alta es un hallazgo, creer que un r cercano a cero significa "no hay relación" y buscar valores raros cuando lo raro es la **combinación**.

2.1 · Covarianza: ¿se mueven para el mismo lado?

Con dos numéricas, lo primero es el **scatter**: un punto por fila, ubicado por sus dos valores. Se mira la dirección (¿cuando una sube, la otra sube o baja?), la fuerza (¿los puntos se pegan a una línea?), la forma (¿recta, curva, grupos?) y los atípicos. Los números vienen después, a resumir lo que se ve.

$$\text{cov}(x, y) = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{n - 1}$$

Cada punto se compara con **su** media en x y con **su** media en y . El $n - 1$ es el mismo de la varianza.

La intuición. Si un punto está arriba de la media en las dos variables (o abajo en las dos), el producto de sus distancias da positivo; si está arriba en una y abajo en la otra, da negativo. La covarianza promedia esos productos: es positiva si suben juntas y negativa si una sube cuando la otra baja. Como cada variable se compara con su propia media, se pueden cruzar variables en unidades distintas.

OJO Su tamaño depende de las unidades. Ingreso $\times$ precio da 150.847 con el ingreso en decenas de miles de dólares, y 1.508.474.828 con el ingreso en dólares: cambió sólo la unidad. De la covarianza **sólo se lee el signo**.

EN PANDAS `x.cov(y)`

2.2 · Correlación de Pearson

$$r = \frac{\text{cov}(x, y)}{s_x \cdot s_y} \quad -1 \leq r \leq 1$$

Dividir por los dos desvíos le saca las unidades. $r = 1$: los puntos caen sobre una recta que sube · $r = 0$: ninguna recta · $r = -1$: una recta que baja.

La intuición. r mide cuánto se parecen los puntos a **una recta**. Como no tiene unidades, se lee solo y se puede comparar entre pares: ingreso $\times$ precio da $r = 0,688$ en dólares o en miles, y es una relación más fuerte que ambientes $\times$ precio (0,134). Una guía gruesa, que es convención y no ley: menos de 0,3 en valor absoluto, débil; de 0,3 a 0,7, moderada; más de 0,7, fuerte.

El heatmap pinta el r de todos los pares numéricos. La diagonal vale 1 (cada variable consigo misma) y es simétrico, así que alcanza con leer una mitad. Sirve para decidir por dónde empezar a mirar, no para concluir. Las categóricas quedan afuera: `ocean_proximity` no aparece.

EN PANDAS `x.corr(y)` `sns.heatmap(df.corr(numeric_only=True), annot=True, cmap="coolwarm", center=0)`

PARA FIJAR De la covarianza sólo se lee el signo; r se lee solo porque no tiene unidades.


2.3 · Correlación no es causalidad

`total_rooms` $\times$ `population` da $r = 0,857$. ¿Más habitaciones atraen más gente, o más gente hace que se construyan más habitaciones? **Ninguna de las dos**: divididas por la cantidad de hogares, $r = -0,005$. Las dos crecían con una tercera variable que no estaba en el gráfico, el **tamaño del barrio**: un barrio con el doble de hogares tiene el doble de todo.

OJO Una correlación altísima puede ser una **tautología**. `total_bedrooms` $\times$ `households` (0,980) es el r más alto del dataset y no descubre nada: más hogares, más dormitorios. El heatmap ordena los pares; qué es importante lo decidís vos, sabiendo qué mide cada columna.

PARA FIJAR Una correlación espuria no es azar: es una variable que no está en el gráfico. Se la caza preguntándose qué más podría estar moviendo a las dos.

2.4 · Los tres límites de r



Las dos de la derecha dan r cercano a 0: una porque no hay relación, la otra porque la relación no es una recta.

1 · Sólo ve rectas. Latitud × precio da $r = -0,144$: parece que no hay relación. Pero por franjas de latitud, el precio es caro en Los Ángeles, barato en el valle central y caro otra vez en la Bahía: una eme. Los tramos que suben y los que bajan se cancelan.

2 · No es la pendiente. Ingreso × precio da más correlación en INLAND (0,699) que en NEAR BAY (0,633), pero menos efecto: cada unidad de ingreso sube el precio 34.056 dólares en INLAND y 38.549 en NEAR BAY. r mide qué tan pegados están los puntos a la recta; la pendiente, cuánto sube.

3 · Con n chico no dice nada. En los cuatro grupos grandes, ingreso × precio da entre 0,63 y 0,70; en ISLAND ($n = 5$) apunta al revés. Sorteando 5 barrios al azar 4.000 veces, r va de $-0,84$ a $+1,00$.

PARA FIJAR Nunca reportes un r sin haber mirado el gráfico.

2.5 · Comparar grupos: groupby y crosstab

Una numérica según el grupo. groupby separa las filas por grupo, calcula algo en cada uno y junta los resultados en una tabla.

```
EN PANDAS df.groupby("ocean_proximity")["median_house_value"].agg(["count", "mean", "median"])
```

Dos categóricas. Ya no se pregunta si "correlacionan", sino si están **asociadas**: si la distribución de una cambia según la categoría de la otra. La herramienta es la tabla cruzada, que casi siempre se normaliza **por fila**:

$$\%_{ij} = \frac{n_{ij}}{n_i} \times 100$$

n_{ij} : los casos del grupo i en la categoría j · n_i : el total del grupo i . Cada fila suma 100%.

La intuición. Los conteos crudos dicen qué grupo es más **grande**: INLAND tiene más barrios baratos (4.928) que <1H OCEAN (1.521) porque tiene más barrios. El % por fila dice cómo se **comporta** cada grupo: 3 de cada 4 barrios de INLAND son baratos (75,2%), contra 1 de cada 6 en <1H OCEAN (16,6%).

OJO Normalizar por columna contesta otra pregunta: el 56% de los barrios del tramo alto es de <1H OCEAN, pero sólo el 30% de los de <1H OCEAN está en el tramo alto. Y pedí siempre el count: ISLAND tiene la media más alta y el único 100% de la tabla (todos sus barrios en el tramo alto), y son 5 barrios. **Un porcentaje sin su n no se reporta.**

```
EN PANDAS pd.crosstab(df["ocean_proximity"], df["tramo"], normalize="index")
```

2.6 · La paradoja de Simpson

En 1973, la Universidad de Berkeley fue demandada por discriminar a las mujeres en las admisiones de posgrado. En el agregado, entraba el 44% de los 8.442 varones y el 35% de las 4.321 mujeres. Abierta por departamento, la tabla dice otra cosa: en 4 de los 6 más grandes, la tasa de las mujeres era **más alta**.

La intuición. Las mujeres se postulaban más a los departamentos más difíciles (C, E y F) y los varones, a los más fáciles (A y B). Ningún número está mal calculado: el agregado mezcla la dificultad del departamento con el género.

departamento	varones	mujeres
A	62%	82%
B	63%	68%
C	37%	34%
D	33%	35%
E	28%	24%
F	6%	7%

El % admitido en cada departamento (Bickel, Hammel y O'Connell, 1975).

PARA FIJAR La misma tabla, en dos niveles, puede dar respuestas opuestas. Preguntate si hay una tercera variable por la que convenga abrirla.

2.7 · Atípicos

El boxplot (sección 1.6) marca como atípico lo que cae fuera de las vallas. Por grupo, sirve para comparar centro, dispersión y colas lado a lado; poné el n en el eje, porque la caja no avisa con cuántos datos se dibujó.

OJO El 1,5 de la regla es una **convención**, no una ley. En housing, con $k = 1,5$ se marcan 1.071 barrios (965 son el tope) y con $k = 3$, ninguno. Hay tres salidas razonables: sacar el tope antes de aplicar la regla, usar $k = 3$, o no usar el IQR (supone una variable más o menos simétrica, y esta está topeada). Lo que no vale es no decidir: se elige una vez y se escribe por qué.

El atípico de par. Un barrio tiene 1.561 ambientes (menos que el 71% de los barrios) y 11 hogares: 142 ambientes por hogar. Es normal en cada variable y absurdo como par. Ninguna regla que mire una columna por vez lo encuentra.

```
EN SEABORN sns.boxplot(data=df, x="ocean_proximity", y="median_house_value")
```

PARA FIJAR Atípico quiere decir "lejos del centro según esta regla", no "error". Y hay atípicos que sólo existen como par.

2.8 · Qué gráfico usar y cómo se arma

qué tenés	la pregunta	el gráfico	en seaborn
1 numérica	¿cómo se distribuye?	histograma o boxplot	histplot · boxplot
2 numéricas	¿se mueven juntas?	dispersión	scatterplot
numérica + grupo	¿cambia según el grupo?	boxplot por grupo	boxplot(x=, y=)
1 categórica	¿cuántos hay de cada uno?	barras	countplot
2 categóricas	¿están asociadas?	crosstab + heatmap	heatmap(crosstab)
muchas numéricas	¿cuáles se relacionan?	heatmap de correlación	heatmap(df.corr())

matplotlib arma, seaborn dibuja. `fig` es la hoja y cada `ax`, un gráfico. Todas las funciones de seaborn tienen la misma receta: `data=` (la tabla), `x=` e `y=` (los nombres de las columnas), `hue=` (una tercera variable, como color) y `ax=` (en qué gráfico de la hoja dibujar; sin él, se pisan). Con muchos puntos, `alpha=` y una muestra no son cosmética: son análisis.

```
EN CÓDIGO fig, axes = plt.subplots(1, 2)      sns.histplot(data=df, x="median_income", ax=axes[0])
```

OJO Ningún gráfico es neutral: en uno de barras, ISLAND es una barra de altura 5 al lado de una de 9.136, invisible. Truncar un eje no está prohibido; truncarlo en silencio, sí. Y explorar (para vos) y comunicar (para alguien que nunca vio los datos) son dos trabajos distintos, con gráficos distintos.

2.9 · El hallazgo, en tres líneas

(1) **Qué se ve**, en lenguaje de persona. (2) **Cuánto es**: el número que lo respalda, con su n. (3) **Qué no podés afirmar**: una razón concreta para dudar.

"Los barrios a menos de una hora del mar valen más que los de tierra adentro. Su precio mediano es de 214.850 dólares, contra 108.500 ($n = 9.136$ y 6.551 barrios). Pero no podemos afirmar que la causa sea el mar: esos barrios también tienen ingresos más altos, y el tope los afecta 14 veces más."

PARA FIJAR Un hallazgo son tres líneas, y la tercera es la que cuesta: "habría que investigar más" no es una razón concreta.

LO QUE TENÉS QUE SABER

1. Una correlación alta puede ser una tautología ($r = 0,980$).
2. Una espuria no es azar: es una variable que no está en el gráfico.
3. La misma tabla, en dos niveles, puede dar respuestas opuestas.
4. Un porcentaje sin su n no se reporta.
5. r sólo ve rectas, no es la pendiente, y con n chico no dice nada.
6. El 1,5 del IQR es una convención: acá marca 1.071 barrios, y 965 son el tope.
7. Hay atípicos que sólo existen como par.
8. Un hallazgo son tres líneas.

PREGUNTAS DE REPASO

- 2.1 Entre dos variables, $r = 0,02$. ¿Podés afirmar que no tienen relación?
- 2.2 En las sucursales de una cadena, la cantidad de empleados y las ventas dan $r = 0,85$. ¿Contratar más empleados aumenta las ventas?
- 2.3 Querés comparar la satisfacción (baja, media o alta) de los clientes de tres sucursales de tamaños muy distintos. ¿Qué tabla armás, y qué no le puede faltar?
- 2.4 Un informe dice: "Los barrios costeros son más caros". Según la regla de las tres líneas, ¿qué le falta?

Inferencia y Machine Learning

LA PREGUNTA DE LA CLASE

¿Esto vale fuera de mis datos?

Hasta acá describimos lo que medimos. Ahora se trata de decir algo de lo que **no** medimos: la primera mitad lo hace con la pobreza que publica el INDEC; la segunda, con un score de crédito. Las dos hacen lo mismo: **generalizar**.

3.1 · Población, muestra y estimación

Según el INDEC, en el primer semestre de 2026 el 32,3% de las personas era pobre. Para saberlo encuestó 52.895 viviendas: un hogar de cada 194, más o menos.

población	todo aquello de lo que querés hablar: las 30,1 millones de personas de los 31 aglomerados urbanos
muestra	lo que mediste: las personas de las 52.895 viviendas encuestadas
estimación	el número que sale de la muestra: 32,3%. El verdadero existe, pero nadie lo conoce.

La intuición. Para saber si la sopa está salada alcanza con una cucharada, **si la revolviste**: una muestra chica alcanza si se elige al azar, y una enorme no sirve si está mal elegida (el *Literary Digest* de la Clase 1). Y la cucharada sólo habla de su olla: la EPH mide ciudades, así que Gran Resistencia no es todo el Chaco.

PARA FIJAR Inferir es ponerle un número a lo que no sabés.

3.2 · El error estándar

Si el INDEC hubiera tocado el timbre en otras 52.895 casas, habría publicado otro número. Con muchas muestras se ve que las estimaciones forman una **campana**: centrada en la verdad y con un ancho. Ese ancho es el **error estándar** (EE): el desvío de las estimaciones.

$$EE = \frac{s}{\sqrt{n}} \quad EE_{\%} = \sqrt{\frac{p(1-p)}{n}} \quad EE = CV \times \text{estimación}$$

La primera es para una media; la segunda, para un porcentaje p (expresado entre 0 y 1); la tercera es como se lee en los informes del INDEC, que publican el CV de cada estimación.

La intuición. Es la misma cuenta del desvío, hecha sobre las **estimaciones** en vez de sobre los datos. Al promediar, los barrios caros y los baratos se compensan: los barrios de housing varían ± 115.396 dólares, pero la media de 100 barrios varía ± 11.540 ($115.396 / \sqrt{100}$). La simulación de la clase dio ± 11.850 : casi lo mismo.

La regla del 4. Cada dato nuevo ayuda, pero menos que el anterior: para achicar el margen a la mitad hacen falta **4 veces más datos**, no el doble. Es la raíz de n de la fórmula. Para pasar de $\pm 1,4$ a $\pm 0,7$ puntos, el INDEC tendría que encuestar unas 211.000 viviendas.

OJO El desvío describe los **datos** y no baja con n ; el EE describe la **estimación** y sí baja. No los confundas.

personas (n)	margen al 95%
100	$\pm 9,2$ puntos
400	$\pm 4,6$ puntos
1.600	$\pm 2,3$ puntos
6.400	$\pm 1,1$ puntos

Una pobreza de 32,3%, medida con muestras de distinto tamaño: cada fila tiene 4 veces más personas y la mitad de margen.

EN PANDAS `ee = x.std() / np.sqrt(len(x))`


3.3 · z y el intervalo de confianza

$$z = \frac{\text{dato} - \text{centro}}{EE} \quad \text{intervalo} = \text{estimación} \pm z \cdot EE$$

z : una distancia medida en errores estándar · $z \cdot EE$: el margen de error.


La intuición. z es una distancia medida en errores estándar, como pasar de pesos a dólares: cambia el número, no la distancia. Con 100 personas, el EE de la pobreza es 4,7 puntos: una muestra que dio 37,0% quedó a $z = +1$ de la verdad (32,3%), y una que dio 23,0%, a $z = -2$. Medidas en errores estándar, todas las campanas son la misma: por eso hay **una sola tabla de z** . Y sus valores no se inventan: se cuentan en la campana.

La receta, con la pobreza del INDEC: (1) la estimación: 32,3%. (2) El EE: $CV \times \text{estimación} = 2,7\% \times 32,3 = 0,87$. (3) La confianza la elegís vos; el INDEC publica al 90%, así que $z = 1,64$. (4) El margen: $1,64 \times 0,87 = 1,4$. (5) El intervalo: $32,3 \pm 1,4 = [30,9 ; 33,7]$ (el INDEC publica $[30,8 ; 33,7]$: es redondeo). Al 95%, $z = 1,96$ y el intervalo es $[30,6 ; 34,0]$: más confianza, más ancho.



z	adentro	afuera
± 1	68%	32%
± 1,64	90%	10%
± 1,96	95%	5%
± 2,58	99%	1%

El perro con correa. Si un perro nunca se aleja del dueño más de lo que da la correa, cuando ves al perro sabés que el dueño anda cerca. La estimación es el perro; la verdad, el dueño; la correa, $z \times EE$.



Veinte muestras de 100 personas y sus intervalos al 95%. Uno no toca la verdad.

Qué significa "95% de confianza". Que de cada 100 intervalos armados así, unos 95 contienen la verdad. **No** significa que tu intervalo tenga 95% de chances: la verdad está adentro o no está; lo que cambia de muestra en muestra es el intervalo. El 95% es una propiedad del método.

Los tres botones del margen: z (lo elegís vos), el desvío (es el mundo: no se toca) y n (tu presupuesto).

OJO Con pocos casos, el CV se dispara. El INDEC lo dice con un semáforo: un CV menor a 16% se puede usar; de 16% a 25%, con cuidado; más de 25%, no es confiable. La indigencia de Formosa (5,9%) tiene un CV de 41,9%: su intervalo al 90% va de 1,8 a 10,0. Es el ISLAND del NEA.

```
EN PANDAS (x.mean() - 1.96 * ee, x.mean() + 1.96 * ee)
```

PARA FIJAR Intervalo = estimación $\pm z \times EE$. El 95% es del método, no de tu intervalo.

3.4 • Contraste de hipótesis

La pobreza pasó de 31,6% (primer semestre de 2025) a 32,3% (primer semestre de 2026), y el INDEC dice que "no se observan cambios significativos". ¿Cómo que no cambió? Cada semestre es una muestra distinta, con su propio error: la pregunta es si esa diferencia puede ser azar.

La moneda y el p-valor. "Esta moneda es justa." La tirás 10 veces: ¿cuántas caras hacen falta para dejar de creerlo? El **p-valor** contesta: si no pasara nada (si la moneda fuera justa), ¿qué tan seguido saldría algo así de extremo por pura suerte? Cuanto más chico, menos creíble es el "no pasó nada".

en 10 tiradas sale	pasa el
6 caras o más	37,7%
8 caras o más	5,5%
9 caras o más	1,1%
10 de 10	0,1%

El juicio. El contraste funciona como un juicio. **H0**, "no pasó nada", es la presunción de inocencia; **H1**, "algo cambió", es la acusación, que tiene que probarlo; y **α** es la duda razonable, el riesgo que aceptás de condenar a un inocente (al 90%, α = 10%: la columna "afuera" de la tabla de z). Bajar α no es gratis: menos condenas injustas, más culpables libres.

	en la realidad no cambió	en la realidad cambió
decís "cambió"	error tipo I: condenar a un inocente	acierto
decís "no cambió"	acierto	error tipo II: absolver a un culpable

$$z = \frac{\text{diferencia} - 0}{EE_{\text{resta}}} \quad EE_{\text{resta}} = \sqrt{EE_1^2 + EE_2^2}$$

La misma z de antes: el dato es la diferencia y el centro es 0, "no pasó nada". Dos mediciones con error suman sus errores al cuadrado, como Pitágoras. Si $|z|$ supera el valor de la tabla (1,64 al 90%), se rechaza H0.

De 31,6% a 32,3%: +0,7 puntos, $z = 0,55$, $p = 0,58$. Sin ningún cambio real, algo así pasa 58 de cada 100 veces: no se rechaza H0. En cambio, del 28,2% del segundo semestre de 2025 al 32,3%: +4,1 puntos, $z = 3,29$, $p = 0,001$. Eso no se explica por azar: la pobreza aumentó.

La regla y el atajo. La regla: armar el intervalo de la diferencia (diferencia $\pm z \times EE_{\text{resta}}$) y ver si deja afuera al 0. Para los +0,7 puntos da $[-1,4 ; +2,8]$: incluye el 0, así que no hay evidencia de cambio. El atajo, "¿el valor anterior cae adentro de mi intervalo?", sirve para mirar rápido, pero trata al otro número como si no tuviera error, y puede engañar.

¿Gran Resistencia (48,6%) es más pobre que Corrientes (41,0%)? El 48,6 queda afuera del intervalo de Corrientes, así que el atajo dice que sí. Pero la diferencia, +7,6 puntos, da $z = 1,12$ y $p = 0,26$, y su intervalo es $[-3,5 ; +18,7]$: **falta de pruebas**. En el NEA, sólo Formosa se separa: de Gran Resistencia ($z = 3,12$) y de Posadas ($z = 2,04$).

pobreza, 1.er semestre 2026	%	al 90%
Total del país	32,3	[30,9 ; 33,7]
Gran Resistencia	48,6	[40,0 ; 57,2]
Posadas	42,2	[33,5 ; 50,9]
Corrientes	41,0	[34,0 ; 48,0]
Formosa	29,9	[25,1 ; 34,7]

Mismo método, anchos distintos: en cada ciudad se encuestaron muchas menos casas.

OJO No rechazar H0 no prueba que no cambió: es absolver por falta de pruebas. Y **significativo no es lo mismo que importante**: con una muestra gigante, el EE es mínimo y hasta 0,1 punto da significativo. Si la diferencia importa, lo decide el problema, no el test.

PARA FIJAR El intervalo de la diferencia tiene que dejar afuera al 0.

3.5 • Machine Learning

¿Quién escribe la regla? En la programación clásica, un analista: "se aprueba si no tuvo atrasos y la cuota es de hasta el 30% del sueldo" (regla + datos → respuesta). En Machine Learning, la máquina la busca en préstamos viejos cuyo resultado ya se conoce (datos + respuestas → regla). El **score** que devuelve, de 0 a 1.000, dice qué tan probable es que la persona pague.

La tabla es la de siempre, con otros nombres: cada **fila** es una persona; las **features** son lo que sabés antes de decidir (edad, sueldo, cuota, atrasos); el **target** es lo que querés predecir (si pagó). El tipo de target decide el problema, como el tipo de variable decidía el gráfico: si es una categoría, es **clasificación** (¿paga o no paga?); si es un número, **regresión** (¿qué límite de tarjeta le doy?); si no hay target, **no supervisado** (agrupar clientes parecidos).

Memorizar no es aprender. En la actividad "Sé el modelo", la regla "pidió el préstamo un martes o un jueves" acertó los 8 préstamos viejos y ninguno de los 4 nuevos; la sensata (sin atrasos y cuota de hasta el 30%), 7 de 8 y 3 de 4. Eso es **sobreajuste**: perfecto con lo que ya vio, malo con lo nuevo. Por eso siempre se separa una parte de los datos que el modelo no ve: **train** y **test**. Es la pregunta del intervalo: ¿esto vale fuera de mis datos?

El baseline. Si 9 de cada 10 clientes pagan, aprobar a todos sin mirar nada ya acierta el 90%. Ese es el modelo más tonto posible, y cualquier modelo tiene que ganarle. "Acierta el 90%", solo, no dice nada.

El umbral reparte los errores. Con H_0 = "esta persona va a pagar", rechazar a un buen pagador es el error tipo I, y aprobar a un moroso, el tipo II. Subir el umbral del score baja uno y sube el otro: no hay umbral que baje los dos. Elegirlo es una decisión de negocio (¿cuánto cuesta un moroso contra un cliente perdido?), y también ética.

se aprueba desde	aprobados	morosos aprobados (tipo II)	buenos rechazados (tipo I)
score 0 (todos)	100%	142	0
score 500	91%	45	36
score 700	85%	24	110
score 950	73%	6	265

1.500 préstamos ficticios de prueba (notebook 06).

OJO: DÓNDE FALLA (1) **La muestra**: la financiera sólo sabe si pagaron los que aprobó; de los rechazados nunca se entera (los aviones de Wald, otra vez). (2) **El mundo cambia**: un modelo entrenado antes de una crisis deja de servir; hay que monitorearlo y reentrenarlo. (3) **El sesgo**: si usa el código postal, puede castigar a un barrio entero. Correlación no es causalidad.

El flujo de un proyecto: la pregunta → los datos → target y features → separar train y test → entrenar → comparar con el baseline → elegir el umbral → monitorear y reentrenar. Los que más se saltan son comparar con el baseline y elegir el umbral. Y la diferencia de fondo: la estadística pregunta **por qué** (¿por qué la gente no paga?); el Machine Learning, **quién** (¿esta persona va a pagar?).

EN SCIKIT-LEARN `train_test_split(X, y)` `modelo.fit(X_train, y_train)` `modelo.predict(X_test)`

PARA FIJAR Machine Learning aprende de ejemplos, y se mide contra un baseline y con datos que no vio.

LO QUE TENÉS QUE SABER

1. Muestras distintas dan números distintos: por eso se publican intervalos.
2. El error estándar es el desvío de las estimaciones, y cae con la regla del 4.
3. z mide distancias en errores estándar: $(\text{dato} - \text{centro}) \div \text{EE}$.
4. Intervalo = estimación $\pm z \times \text{EE}$. El 95% es del método, no de tu intervalo.
5. Si el valor anterior cae dentro del intervalo nuevo, el cambio puede ser azar.
6. La regla: el intervalo de la diferencia tiene que dejar afuera al 0.
7. En el NEA, sólo Formosa se separa; entre las otras tres ciudades, falta de pruebas.
8. Machine Learning aprende de ejemplos: se mide contra un baseline y con datos nuevos.

PREGUNTAS DE REPASO

- 3.1** Una encuesta a 400 personas da 30%, con un margen de $\pm 4,5$ puntos. ¿A cuántas personas habría que encuestar para tener un margen de $\pm 2,25$?
- 3.2** El intervalo de 95% para el sueldo medio de una empresa es [180.000 ; 220.000]. ¿Está bien decir "hay 95% de probabilidad de que el sueldo medio real esté entre 180.000 y 220.000"?
- 3.3** La pobreza de una ciudad pasa de 40% (EE = 2 puntos) a 44% (EE = 2 puntos). ¿El aumento es significativo al 90%?
- 3.4** Un modelo de crédito acierta el 91% de los casos de test, y 9 de cada 10 clientes pagan. ¿Es un buen modelo?

Hoja de fórmulas

qué	fórmula	qué mide	dónde se rompe
UNA VARIABLE · CLASE 1			
Media	$\bar{x} = \frac{1}{n} \sum x_i$	el centro, como punto de equilibrio	la mueven los extremos, sobre todo con n chico
Mediana	el valor del medio, con los datos ordenados	el centro, sin que importen los extremos	es la que conviene con colas o errores
Frecuencias	$f_i = n_i / n \cdot F_i = n_1 + \dots + n_i$	cómo se reparten los valores	en una continua, depende de los tramos elegidos
IQR y vallas	$IQR = Q_3 - Q_1$ $Q_1 - 1,5 IQR \cdot Q_3 + 1,5 IQR$	el ancho del 50% central; los atípicos	el 1,5 es una convención
Varianza	$s^2 = \frac{\sum (x_i - \bar{x})^2}{n - 1}$	la dispersión	está en unidades al cuadrado; numpy divide por n
Desvío estándar	$s = \sqrt{s^2}$	la distancia típica al centro	no compara variables de escalas distintas
Coef. de variación	$CV = s / \bar{x}$	la dispersión relativa, sin unidades	con n chico engaña; sólo para variables positivas
DOS VARIABLES · CLASE 2			
Covarianza	$\frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{n - 1}$	si se mueven juntas, y hacia dónde	depende de las unidades: sólo se lee el signo
Correlación	$r = \frac{\text{cov}(x, y)}{s_x s_y}$	cuán pegados están los puntos a una recta	sólo ve rectas, no es la pendiente y con n chico no dice nada
% por fila	$n_{ij} / n_i \times 100$	cómo se reparte cada grupo	sin su n no se reporta
INFERENCIA · CLASE 3			
Error estándar	$s / \sqrt{n}$ para una media $\sqrt{p(1-p)/n}$ para un porcentaje CV × estimación (INDEC)	cuánto cambia la estimación de muestra en muestra	no es el desvío de los datos
z	$\frac{\text{dato} - \text{centro}}{EE}$	una distancia, en errores estándar	1,64 al 90% · 1,96 al 95% · 2,58 al 99%
Intervalo	estimación $\pm z \cdot EE$	dónde puede estar la verdad	el 95% es del método, no de tu intervalo
EE de una resta	$\sqrt{EE_1^2 + EE_2^2}$	el error de una diferencia	supone muestras independientes
z de una diferencia	$\frac{\text{diferencia} - 0}{EE_{\text{resta}}}$	a cuántos EE está de "no pasó nada"	significativo no es lo mismo que importante

Las reglas que conviene recordar

La regla del 4. Para achicar el margen a la mitad hacen falta 4 veces más datos.

El semáforo del CV (INDEC). Menos de 16%: se puede usar · de 16% a 25%: con cuidado · más de 25%: no es confiable.

El contraste. Si el intervalo de la diferencia incluye el 0, no podés afirmar que haya diferencia: es falta de pruebas, no prueba de igualdad.

La guía de r (una convención). Menos de 0,3 en valor absoluto: débil · de 0,3 a 0,7: moderada · más de 0,7: fuerte.

pandas y numpy. `.var()` y `.std()` de pandas dividen por $n - 1$; `np.var()` y `np.std()`, por n.

El hallazgo. Qué se ve · cuánto es, con su n · qué no podés afirmar.

Respuestas del repaso

Clase 1 • Fundamentos

- 1.1 No necesariamente. El tamaño no corrige el sesgo: contesta quien quiere (suelen ser los muy conformes o los muy enojados), y los que se fueron no están. Más respuestas de la gente equivocada siguen siendo de la gente equivocada.
- 1.2 Tiene una cola a la derecha: unos pocos ingresos muy altos tiran de la media hacia arriba. Como "ingreso típico" conviene la mediana: 620.000.
- 1.3 La media es 5; las distancias, -3 , -1 y 4 ; al cuadrado suman $9 + 1 + 16 = 26$. Dividido por $n - 1 = 2$, la varianza es 13 y el desvío, $\sqrt{13} \approx 3,61$. Dividido por $n = 3$ da 8,67: la versión con $n - 1$ es un 50% más grande, porque $n/(n - 1) - 1 = 3/2 - 1$. Con n tan chico, la diferencia pesa.
- 1.4 Por desvío parece B (300 contra 40), pero esa comparación no sirve: las escalas son distintas. Por CV, la más variable es A: $40 / 200 = 0,20$, contra $300 / 2.000 = 0,15$.

Clase 2 • Bivariado y visualización

- 2.1 No. r sólo mide relaciones lineales: puede haber una relación fuerte que no sea una recta, como la eme de la latitud y el precio. Hay que mirar el scatter.
- 2.2 No necesariamente. Puede haber una variable que no está en el gráfico: el tamaño de la sucursal, que hace crecer a las dos. Para acercarse, habría que comparar sucursales de tamaño parecido, o mirar las ventas por metro cuadrado.
- 2.3 Una tabla cruzada sucursal $\times$ satisfacción, normalizada por fila (cada sucursal suma 100%), con el n de cada sucursal a la vista.
- 2.4 Le faltan la segunda y la tercera línea: cuánto es (el número, con su n) y qué no se puede afirmar; por ejemplo, que la causa sea la costa, si esos barrios también tienen ingresos más altos.

Clase 3 • Inferencia y Machine Learning

- 3.1 1.600 personas: para achicar el margen a la mitad hacen falta 4 veces más datos.
- 3.2 No. El 95% es una propiedad del método: de cada 100 intervalos armados así, unos 95 contienen el sueldo medio real. Este intervalo en particular lo contiene o no lo contiene.
- 3.3 El EE de la resta es $\sqrt{(2^2 + 2^2)} = 2,83$, y $z = 4 / 2,83 = 1,41$, menos que 1,64: no se rechaza H_0 , falta de pruebas. El intervalo de la diferencia, $4 \pm 1,64 \times 2,83 = [-0,6 ; 8,6]$, incluye el 0.
- 3.4 No alcanza con ese número: aprobar a todos ya acierta el 90%, así que el modelo le gana al baseline por un punto. Además hay que mirar qué errores comete: un 91% puede esconder muchos morosos aprobados, y eso se decide con el umbral.